# Rispondere senza sapere: Discursive Strategies* of Large Language Models Under Information Scarcity. The Case of *Fanciulla di Vagli*

Paolo Labruna
pielleunipi@gmail.com

**Abstract**

This work analyzes the discursive strategies adopted by five Large Language Models (LLMs) when they are queried about poorly documented knowledge subjects. Through a case study — the *Fanciulla di Vagli* — the responses of different closed-source models to a single prompt are examined, considering factual accuracy, discursive strategies, and source attribution.

The results show that, under conditions of information scarcity, models tend to fill informational gaps through referential substitutions, culturally plausible narratives, and assertively formulated inferences. Requesting sources does not necessarily guarantee greater correctness; instead, it often introduces forms of post-hoc legitimization, such as non-binding citations or simulated bibliographic apparatuses.

The case thus highlights a systematic gap between discursive plausibility and epistemic verifiability.

**Keywords:** Large Language Models (LLM); LLM hallucinations; discursive strategies; low-information contexts; source attribution; epistemic authority; *Fanciulla di Vagli*.

*Nel presente lavoro il termine "strategie discorsive" è utilizzato per indicare configurazioni ricorrenti di scelte linguistiche e strutturali indipendentemente da qualsiasi forma di intenzionalità del sistema.

# 1 Introduzione

Negli ultimi anni, i *Large Language Models* (LLM) si sono imposti come strumenti centrali nell'accesso e nella mediazione della conoscenza digitale. Integrati in motori di ricerca, assistenti virtuali e sistemi di supporto decisionale, questi modelli sono sempre più percepiti come fonti autorevoli di informazione, capaci di fornire risposte fluide, coerenti e spesso convincenti su un'ampia varietà di argomenti.

Tuttavia, tale autorevolezza discorsiva non coincide necessariamente con una reale disponibilità di conoscenza. I modelli linguistici generativi non interrogano direttamente una base di dati strutturata, né possiedono una rappresentazione esplicita dei limiti della propria competenza. Essi operano invece attraverso la generazione probabilistica di sequenze linguistiche, basata su regolarità apprese durante la fase di addestramento. In questo contesto, quando un argomento è scarsamente documentato o poco rappresentato nei dati di training, il modello si trova nella condizione di dover rispondere *senza sapere*.

Questo lavoro si colloca all'interno di una riflessione più ampia sulle modalità con cui gli LLM producono risposte in condizioni di incertezza informativa, interrogandosi sulle strategie discorsive attraverso cui tali sistemi colmano vuoti di conoscenza e costruiscono affidabilità testuale anche in assenza di dati solidi.

Per affrontare queste domande, la relazione prende in esame un caso di studio specifico: la Fanciulla di Vagli. Si tratta di una sepoltura contenente i resti di una cremazione, deposti in un'urna cineraria e inseriti in un monumento funerario ligure-apuano dei primi decenni del II secolo a.C.. Rinvenuto nel 2008 nei pressi del cimitero di Vagli di Sopra, il contesto è oggetto di una voce Wikipedia creata dall'autore nel 2016[1], ed è caratterizzato da una limitata circolazione di fonti secondarie online. A partire da una domanda apparentemente semplice — *"Che cos'è la Fanciulla di Vagli?"* — si analizzano le risposte fornite da diversi LLM chiusi, confrontandone contenuti, accuratezza fattuale, stile argomentativo e gestione delle fonti.

L'obiettivo non è valutare le prestazioni dei modelli in termini di correttezza assoluta, ma osservare il modo in cui essi costruiscono il discorso in condizioni di scarsità informativa. In particolare, l'attenzione è rivolta agli errori, alle imprecisioni e alle eventuali *allucinazioni*, intese non solo come affermazioni false, ma come strategie linguistiche di riempimento, normalizzazione e legittimazione del sapere prodotto.

Attraverso un'analisi qualitativa delle risposte e una verifica manuale delle fonti citate, il lavoro intende mostrare come, in assenza di conoscenza consolidata, gli

[1] `https://it.wikipedia.org/wiki/Fanciulla_di_Vagli`

LLM tendano a fare ricorso a schemi narrativi e culturali preesistenti, privilegiando la verosimiglianza rispetto alla verificabilità. In questo senso, il caso della Fanciulla di Vagli diventa un osservatorio privilegiato per riflettere sul rapporto tra intelligenza artificiale, autorità epistemica e costruzione della conoscenza nell'ecosistema digitale contemporaneo.

Un possibile punto critico dell'impostazione riguarda i sistemi che dichiarano (o possono attivare) funzionalità di consultazione del web o di *retrieval* esterno. In tal caso, l'esperimento non misurerebbe più soltanto ciò che il modello "sa" in virtù dell'addestramento, ma anche la sua capacità di selezionare, leggere e sintetizzare fonti scarse o frammentarie. Un'eventuale risposta errata non sarebbe quindi attribuibile univocamente a un limite di copertura del training-set, ma potrebbe dipendere da errori di interpretazione, sintesi distorta o *overconfidence* discorsiva.

Questa ambiguità non è eliminabile con certezza a partire dalle sole risposte. Tuttavia, essa non invalida l'impianto dell'analisi: in entrambi i casi — sia che il modello attinga esclusivamente alla conoscenza pregressa, sia che consulti fonti esterne — la "scarsità informativa" resta una condizione operante, che si manifesta come assenza di dati consolidati nel training o come difficoltà di reperimento e interpretazione di evidenze frammentarie. Ciò che l'analisi osserva sono le strategie discorsive con cui gli LLM costruiscono affidabilità in tale condizione, indipendentemente dalla provenienza specifica delle informazioni.

# 2 Metodo

Il presente lavoro adotta un approccio qualitativo basato su un caso di studio, con l'obiettivo di osservare e analizzare il comportamento discorsivo di diversi Large Language Models (LLM) in una situazione di scarsità informativa. L'analisi non mira a una valutazione quantitativa delle prestazioni, ma a una comprensione critica delle strategie linguistiche e argomentative adottate dai modelli quando sono chiamati a rispondere a una domanda relativa a un oggetto di conoscenza poco documentato.

## 2.1 Scelta del caso di studio

Il caso di studio selezionato è la *Fanciulla di Vagli*, la scelta di questo soggetto è motivata da tre fattori principali: la limitata diffusione di fonti secondarie online, la natura specialistica dell'argomento e la presenza di una voce enciclopedica che funge da riferimento verificabile per l'analisi delle risposte.

La *Fanciulla di Vagli* rappresenta dunque un esempio di conoscenza digitale scarsamente rappresentato nell'ecosistema informativo del web particolarmente adatto

a mettere in evidenza eventuali lacune, approssimazioni o strategie di riempimento adottate dai modelli linguistici.

## 2.2 Domanda di ricerca

A tutti i modelli considerati è stata posta la medesima domanda, formulata in modo intenzionalmente semplice e non guidato:

> *"Che cos'è la Fanciulla di Vagli?"*

La scelta di una domanda aperta e volta a ottenere una descrizione di base consente di osservare liberamente le modalità con cui ciascun modello costruisce la propria risposta, senza vincoli di formato o suggerimenti contestuali.

In una seconda fase, a seguito della prima domanda è stata sottoposta una richiesta esplicita di indicazione delle fonti utilizzate, al fine di analizzare il comportamento dei modelli rispetto alla giustificazione epistemica delle informazioni fornite.

## 2.3 Selezione dei modelli e costruzione del corpus

L'analisi è stata condotta su un numero limitato di LLM chiusi, selezionati per la loro diffusione e la disponibilità di *web chat*. In particolare, sono stati analizzati i modelli DeepSeek-V3, ChatGPT-4o, Gemini 3, Claude Sonnet 4.5 e Mistral Large. La scelta di modelli chiusi riflette una condizione d'uso realistica e diffusa, in cui non è possibile accedere né ai dati di addestramento né ai meccanismi interni di funzionamento.

Per ciascun modello è stata raccolta una risposta, mantenendo invariata la formulazione del prompt e senza fornire contesto aggiuntivo o documentazione esterna.

Le risposte generate dai modelli costituiscono il corpus testuale analizzato in questo studio. Tutti gli output sono stati trascritti integralmente e conservati senza modifiche.

## 2.4 Criteri di analisi

L'analisi delle risposte è stata condotta manualmente secondo una griglia qualitativa, articolata lungo quattro dimensioni principali:

- **Accuratezza fattuale**: corrispondenza delle affermazioni fornite rispetto alle informazioni verificabili presenti nella voce Wikipedia e nelle fonti disponibili.

- **Strategie discorsive**: modalità retoriche e narrative adottate dai modelli, quali tono assertivo, cautela epistemica, ricorso ad analogie o strutture enciclopediche standard.
- **Gestione delle fonti**: presenza o assenza di riferimenti espliciti, distinzione tra fonti reali, vaghe o non verificabili.
- **Tipologia di errore**: identificazione di imprecisioni, generalizzazioni indebite o forme di *hallucination*, sia fattuali sia relative alle fonti.

Questi criteri permettono un'analisi comparativa delle risposte che tenga conto non solo della correttezza delle informazioni, ma anche delle modalità con cui la conoscenza viene costruita e presentata.

### 2.5 Limiti del metodo

È opportuno sottolineare che il presente studio non consente di trarre conclusioni generalizzabili sul funzionamento dei LLM in senso assoluto. L'analisi è circoscritta a un singolo caso di studio e a un numero limitato di modelli. Inoltre, non è possibile risalire con certezza alle fonti di addestramento dei modelli analizzati; le considerazioni sulle fonti restano pertanto di natura interpretativa e discorsiva.

Tuttavia, proprio per la sua natura circoscritta e qualitativa, il metodo adottato si rivela adeguato a mettere in luce dinamiche significative nella produzione del discorso da parte degli LLM in condizioni di scarsità informativa.

## 3 Analisi del modello Mistral Large

### 3.1 Descrizione della risposta

Il modello Mistral descrive la *Fanciulla di Vagli* come una statuetta in steatite risalente all'età del rame (III millennio a.C.), scoperta nel 1957 durante scavi archeologici in Garfagnana. La risposta attribuisce all'oggetto una funzione simbolica legata alla fertilità, ne descrive lo stile come stilizzato e geometrico, e afferma che il reperto sarebbe oggi conservato presso il Museo Archeologico Nazionale di Firenze.

La risposta è strutturata in modo ordinato e segue un impianto tipicamente enciclopedico, includendo una definizione iniziale, un elenco di caratteristiche principali e una collocazione istituzionale finale.

## 3.2 Analisi dell'errore

Il confronto con le informazioni verificabili mostra uno scarto netto e sistematico.

La risposta del modello non presenta semplici imprecisioni, ma propone una ricostruzione completamente alternativa dell'oggetto di conoscenza. La natura del reperto viene completamente alterata: da urna cineraria inserita in un monumento funerario ligure-apuano di età repubblicana, a statuetta preistorica legata a culti della fertilità. Anche la data di rinvenimento (1957 invece di 2008) e il luogo di conservazione risultano inventati.

L'errore osservato può essere classificato come una forma di *sostituzione per analogia culturale*. La tipologia di oggetto evocata dal modello non è arbitraria. In Italia sono infatti note diverse statuette preistoriche in steatite, rinvenute in contesti come Savignano [2], Massaciuccoli [3] e il lago di Bracciano, generalmente riferibili al Paleolitico o al Neolitico. Tuttavia, non esistono attestazioni di reperti di questo tipo né a Vagli né, più in generale, nell'area della Garfagnana. Il modello sembra quindi attingere a un repertorio archeologico reale e culturalmente consolidato, ricollocandolo in modo improprio rispetto al contesto geografico e cronologico specifico. Il modello non fornisce una risposta vaga o parzialmente errata, ma sostituisce l'intero referente con un altro oggetto archeologico plausibile, attingendo a un repertorio iconografico e narrativo molto diffuso nella divulgazione storica e archeologica. In questo senso, la Fanciulla di Vagli non viene descritta erroneamente, ma viene di fatto *ricreata* come un oggetto diverso, coerente con schemi culturali ben noti.

## 3.3 Strategie discorsive

Dal punto di vista discorsivo, la risposta presenta un elevato grado di verosimiglianza. Il lessico specialistico (ad esempio "steatite", "età del rame", "eneolitico") contribuisce a creare un effetto di competenza tecnica. La struttura testuale ricalca quella di una scheda museale o di una voce enciclopedica, rafforzando ulteriormente la credibilità della risposta.

Un elemento particolarmente significativo è il riferimento a un'istituzione culturale autorevole, il Museo Archeologico Nazionale di Firenze, che svolge una funzione di legittimazione dell'informazione. Tale riferimento, pur essendo infondato, contribuisce a rendere la risposta persuasiva agli occhi del lettore non specialista.

La risposta non presenta alcun elemento di cautela epistemica. Non vengono utilizzate espressioni di incertezza né viene ammessa la possibilità di una conoscenza

[2] La Venere di Savinano è attualmente esposta nel Museo delle Civiltà a Roma

[3] La statuina è conservata presso i Civici Musei di Villa Paolina, Museo Preistorico e Archeologico Alberto Carlo Blanc di Viareggio

incompleta. Al contrario, le informazioni vengono presentate con sicurezza e assertività, nonostante siano interamente non verificabili. L'assenza di dubbi o cautele evidenzia una tendenza all'overconfidence, particolarmente problematica in contesti di scarsità informativa.

## 3.4 Gestione delle fonti

A seguito della richiesta esplicita di indicare le fonti utilizzate, il modello ha fornito un elenco di riferimenti che include la voce Wikipedia dedicata al reperto, il sito istituzionale Archeotoscana e un articolo del quotidiano *Il Tirreno*. A differenza di altri casi di *uso improprio delle fonti*, le fonti citate risultano effettivamente esistenti e pertinenti rispetto all'oggetto di studio.

Tuttavia, si evidenzia una discrepanza significativa tra le fonti elencate e il contenuto della risposta precedentemente fornita. Le fonti citate descrivono la Fanciulla di Vagli come una sepoltura ligure-apuana contenente i resti di una cremazione, databile ai primi decenni del II secolo a.C. Al contrario, la risposta presentava l'oggetto come una statuetta preistorica in steatite risalente all'età del rame. La citazione delle fonti avviene dunque *a posteriori*, senza un reale rapporto di derivazione tra i documenti menzionati e il contenuto della risposta. In questo senso, non si è in presenza di fonti inventate, ma di un uso improprio di fonti reali come strumento di legittimazione discorsiva.

Un ulteriore elemento problematico è rappresentato dalla formulazione adottata dal modello, che afferma di aver "consultato" tali fonti. Questa espressione suggerisce un'attività di ricerca e verifica che non è possibile ricostruire o verificare a partire dalla risposta fornita. Anche assumendo un eventuale accesso alle fonti citate, la discrepanza tra i contenuti dei documenti menzionati e le affermazioni prodotte indica che tali fonti non hanno esercitato un ruolo informativo sul testo generato.

Questo comportamento può essere interpretato come una forma di uso retorico delle fonti, in cui riferimenti reali e pertinenti vengono impiegati per legittimare un contenuto che da essi non deriva. Il modello non inventa le fonti, ma le utilizza come strumento discorsivo per sostenere una risposta priva di fondamento fattuale. La presenza di riferimenti autorevoli non riduce l'errore, ma contribuisce a mascherarlo, aumentando il rischio di accettazione acritica da parte del lettore.

In condizioni di scarsità informativa, le fonti perdono la loro funzione di strumento di controllo epistemico e vengono impiegate come elemento di legittimazione del discorso.

# 4 Analisi del modello Claude Sonnet 4.5

## 4.1 Descrizione della risposta

Il modello Claude identifica la Fanciulla di Vagli con il campanile sommerso di Fabbriche di Careggine, un paese medievale che emerge dalle acque del Lago di Vagli in occasione dello svuotamento del bacino artificiale. La risposta fornisce una descrizione dettagliata del campanile, della storia del villaggio sommerso e delle emersioni documentate nel corso del tempo.

La struttura della risposta è articolata in sezioni tematiche, con una ricostruzione storica ordinata e un elenco delle principali emersioni. Il tono è informativo e narrativamente efficace, seguendo uno schema tipico della divulgazione storico-turistica.

## 4.2 Analisi dell'errore

La descrizione fornita è storicamente accurata per quanto riguarda il campanile e il villaggio sommerso di Fabbriche di Careggine, ma risulta completamente errata rispetto all'oggetto della domanda.

L'errore può essere interpretato come una forma di *confusione referenziale*, probabilmente dovuta alla prossimità geografica e alla forte associazione simbolica tra il toponimo "Vagli" e il campanile sommerso, uno degli elementi più noti del paese sommerso. In assenza di una conoscenza specifica sulla Fanciulla di Vagli, il modello sembra aver privilegiato un referente conosciuto, sostituendo l'oggetto reale ma poco noto con uno riconosciuto nell'immaginario collettivo.

Questo tipo di errore si distingue da una vera e propria *allucinazione* nel senso di invenzione di contenuti: il modello non crea un oggetto inesistente, ma sostituisce il referente corretto con uno reale, noto e documentato. La sostituzione semantica sfrutta un oggetto simbolicamente forte per colmare un vuoto informativo.

## 4.3 Strategie discorsive

Dal punto di vista discorsivo, la risposta è strutturata in modo ordinato e narrativamente efficace. La suddivisione in sezioni, la ricostruzione storica e l'elenco delle emersioni contribuiscono a rafforzare la credibilità dell'output. Il linguaggio adottato è quello tipico della divulgazione culturale di qualità: chiaro, accessibile ma non semplicistico, con riferimenti precisi a date e eventi.

Un elemento particolarmente problematico è l'affermazione secondo cui il campanile sommerso sarebbe "più comunemente" noto come Fanciulla di Vagli. Non risultano attestazioni storiche, documentarie o nell'uso locale che supportino tale

denominazione. L'uso dell'avverbio "comunemente" conferisce autorità e apparente legittimità a un'identificazione errata, trasformando una confusione referenziale in una presunta prassi linguistica condivisa.

Non sono presenti segnali di incertezza o cautela epistemica: l'identificazione viene presentata come un fatto acquisito, senza alcuna cautela. Questa sicurezza assertiva contrasta con la natura dell'errore e mostra come, in contesti di scarsità informativa, gli LLM possano privilegiare la notorietà culturale e narrativa rispetto alla precisione referenziale.

## 4.4 Gestione delle fonti

A seguito della richiesta di chiarimento sulle fonti utilizzate, il modello ha risposto dichiarando di aver fatto affidamento esclusivamente sulle proprie conoscenze di addestramento, specificando che tali conoscenze si fermano a gennaio 2025. Il modello ha inoltre segnalato la possibile obsolescenza delle informazioni relative al campanile sommerso di Fabbriche di Careggine e ha offerto la possibilità di effettuare una ricerca sul web per ottenere dati più aggiornati.

Dal punto di vista formale, questa risposta appare epistemicamente corretta. Il modello non simula una consultazione diretta di fonti esterne, ma descrive il proprio funzionamento in termini generali, chiarendo i limiti temporali del proprio addestramento e distinguendo tra conoscenza pregressa e ricerca in tempo reale. Tale comportamento introduce un livello di trasparenza procedurale assente in altri casi analizzati.

Tuttavia, questa correttezza non incide sull'errore sostanziale già osservato. La risposta continua infatti a identificare la Fanciulla di Vagli con il campanile sommerso di Fabbriche di Careggine, mantenendo invariata la sostituzione precedentemente analizzata. La spiegazione del processo di generazione della risposta avviene dunque interamente all'interno di una cornice semantica errata.

Questo comportamento può essere interpretato come una forma di *spiegazione trasparente ma non correttiva*: il modello spiega in modo accurato come produce conoscenza e quali sono i suoi limiti, ma non mette in discussione l'identificazione dell'oggetto di cui sta parlando. La trasparenza sul funzionamento non si traduce in una revisione critica del contenuto.

Dal punto di vista dell'utente, tale risposta risulta particolarmente persuasiva. La dichiarazione dei limiti, unita alla proposta di una verifica esterna, contribuisce a rafforzare l'impressione di affidabilità e competenza, nonostante l'errore fattuale rimanga irrisolto. Questo caso mostra come, nei Large Language Models, spiegazioni chiare sul funzionamento del modello possano convivere con errori sul contenuto, e

come una presentazione metodologicamente trasparente possa rendere più credibile una risposta sbagliata.

# 5 Analisi del modello DeepSeek-V3

## 5.1 Descrizione della risposta

Il modello DeepSeek interpreta la Fanciulla di Vagli non come un reperto archeologico, ma come una figura leggendaria legata al lago artificiale di Vagli e al paese sommerso di Fabbriche di Careggine. La risposta contiene un racconto che intreccia elementi storici reali, come la costruzione della diga nel 1947 e l'immersione del villaggio medievale, con componenti leggendarie, tra cui l'esistenza di una giovane donna sepolta nei pressi del cimitero e la possibilità che il suo fantasma riemerga quando il livello dell'acqua si abbassa.

Il tono della risposta è evocativo e narrativo, con riferimenti espliciti al mistero e al fascino del luogo. La struttura segue uno schema tipico del racconto folklorico, con elementi di memoria collettiva e suggestioni emotive.

## 5.2 Analisi dell'errore

Il modello, in assenza di una conoscenza specifica sul reperto archeologico noto come Fanciulla di Vagli, propone una struttura narrativa attingendo a una tradizione folklorica locale effettivamente attestata.

La risposta evoca, pur non nominandola, Teodora, figura femminile oggetto di sospetto e diffidenza da parte della comunità, nella memoria collettiva del borgo di Fabbriche di Careggine, associata alla sommersione del paese in seguito alla costruzione del bacino idroelettrico. Tale tradizione non presenta alcun legame storico o archeologico con il reperto denominato Fanciulla di Vagli.

L'interpretazione proposta dal modello è problematica anche sul piano lessicale. La figura leggendaria a cui la risposta rimanda è una donna adulta e sposata a cui il termine "fanciulla" non si addice.

Nella risposta del modello manca qualsiasi riferimento al reperto archeologico, e l'oggetto della domanda è riformulato esclusivamente nei termini di una tradizione leggendaria e di una memoria narrativa locale.

## 5.3 Strategie discorsive

Dal punto di vista discorsivo, la risposta si presenta esplicitamente come il racconto di una leggenda locale, adottando un lessico evocativo e facendo riferimento alla memoria collettiva territoriale. Questa modalità narrativa risulta culturalmente plausibile e coerente, ma non pertinente rispetto all'oggetto specifico della domanda.

## 5.4 Gestione delle fonti

In risposta alla richiesta di indicare le fonti utilizzate, il modello DeepSeek non fornisce riferimenti specifici, ma descrive in termini generali il proprio processo di addestramento, richiamando una banca di conoscenze generali di tipo storico, geografico e folkloristico. Il modello dichiara di non avere accesso a fonti puntuali né a dati in tempo reale, introducendo un livello di cautela procedurale assente nella risposta iniziale.

In assenza di fonti verificabili, il modello fa riferimento a categorie generiche come "folklore locale", "articoli divulgativi" o "guide turistiche", che non consentono una verifica diretta delle affermazioni. La fonte diventa così un ambito discorsivo indistinto, con una conseguente attenuazione della responsabilità epistemica. L'invito finale a consultare enti istituzionali o risorse locali rafforza l'impressione di affidabilità, senza tuttavia fornire strumenti concreti per la verifica.

# 6 Analisi del modello ChatGPT-4o

## 6.1 Descrizione della risposta

Il modello ChatGPT-4o identifica la Fanciulla di Vagli come una statua in marmo bianco di Carrara, realizzata nel 2001 dall'artista toscano Giuliano Vangi e collocata nei pressi del lago artificiale di Vagli come monumento commemorativo delle vittime [4] della sommersione del paese di Fabbriche di Careggine. La risposta presenta una descrizione dettagliata dell'opera, del suo significato simbolico e del contesto storico a cui sarebbe legata.

La struttura della risposta è articolata e narrativamente efficace, con riferimenti precisi a date, nomi propri e contesti culturali. Il tono è quello tipico della divulgazione culturale specializzata, con particolare attenzione agli aspetti simbolici e commemorativi dell'opera.

[4] La sommersione del paese, in realtà, non causò vittime.

## 6.2 Analisi dell'errore

La descrizione fornita dal modello è interamente inventata: non esiste alcuna statua di Giuliano Vangi dedicata alla Fanciulla di Vagli, né risultano attestati progetti commemorativi legati al reperto archeologico. L'errore osservato può essere interpretato come una forma di assemblaggio fittizio di elementi reali, in cui dati storicamente attestati (la sommersione di Fabbriche di Careggine, il lago artificiale di Vagli, l'esistenza dello scultore Giuliano Vangi e di progetti di valorizzazione culturale) vengono combinati in una narrazione coerente ma priva di fondamento fattuale.

Non si tratta di una semplice confusione o di una rielaborazione folklorica, bensì dell'attribuzione arbitraria di un'opera d'arte inesistente a un autore reale e a un contesto storico e culturale verosimile. In questo processo, elementi appartenenti a piani disciplinari differenti — archeologia, storia contemporanea, arte monumentale e promozione turistica — vengono fusi senza distinzione, producendo un discorso unitario che sostituisce il referente archeologico con un oggetto artistico immaginario.

## 6.3 Strategie discorsive

La risposta di ChatGPT-4o adotta una modalità narrativa tipica della divulgazione culturale e commemorativa. L'uso di un lessico evocativo e di dettagli visivi e materiali produce un forte effetto di concretezza e verosimiglianza.

Un elemento centrale della strategia discorsiva è l'elevata precisione apparente: date, nomi propri, materiali e collocazioni vengono forniti con sicurezza, rafforzando la credibilità dell'output. Questa precisione formale contribuisce a mascherare il carattere fittizio delle informazioni descritte.

La narrazione segue schemi retorici consolidati, legati alla memoria storica e all'identità territoriale. In assenza di segnali di cautela epistemica, il modello presenta la propria ricostruzione in modo completo, privilegiando la coerenza narrativa e la plausibilità culturale rispetto alla correttezza fattuale.

## 6.4 Gestione delle fonti

A seguito della richiesta di indicare le fonti utilizzate, il modello ChatGPT-4o ha dichiarato di non aver consultato fonti esterne in tempo reale, specificando che la risposta si basa sulla conoscenza pre-addestrata fino al 2024 e su dati provenienti da fonti pubblicamente disponibili.

Le categorie di fonti menzionate includono siti turistici e culturali dedicati alla Garfagnana e alla Toscana, articoli e guide su Vagli Sotto, sul lago artificiale di Vagli

e sul paese sommerso di Fabbriche di Careggine, informazioni generali sull'opera e sulla biografia dello scultore Giuliano Vangi, nonché notizie diffuse dalla stampa italiana riguardanti statue installate a Vagli e presunti progetti di valorizzazione culturale.

La risposta presenta una trasparenza procedurale: il modello non finge di aver consultato fonti, ma dichiara apertamente di basarsi sulla propria conoscenza di addestramento, specificandone i limiti temporali e offrendo la possibilità di una verifica esterna.

Tuttavia, tale correttezza procedurale non incide sulla validità del contenuto informativo. Le fonti elencate, pur essendo plausibili e coerenti con la narrazione proposta, non risultano pertinenti rispetto al referente reale della Fanciulla di Vagli. La funzione delle fonti citate non è quella di verificare il contenuto, ma di consolidare una costruzione narrativa errata.

Il modello non ricorre a una singola fonte impropria, ma costruisce una rete di riferimenti generici coerenti sul piano semantico e culturale, che rendono la risposta internamente solida e persuasiva. La pluralità delle fonti e la loro apparente autorevolezza contribuiscono a rafforzare la credibilità dell'output, rendendo meno evidente l'errore di base.

Dal punto di vista dell'utente, tale strategia produce un forte effetto di affidabilità. La citazione di categorie ampie di fonti seppur generiche (siti istituzionali, stampa, guide turistiche, biografia dell'artista) suggerisce un processo di ricerca approfondito e multifonte, mascherando il fatto che l'oggetto stesso della risposta è interamente inventato. Questo caso mostra come, nei Large Language Models, la citazione delle fonti possa svolgere una funzione prevalentemente retorica, stabilizzando un discorso verosimile ma fattualmente scorretto.

# 7 Analisi del modello Gemini 3

## 7.1 Descrizione della risposta

Il modello Gemini identifica correttamente l'oggetto della domanda come un reperto archeologico e fornisce una descrizione ampiamente coerente con le informazioni verificabili disponibili nelle fonti. Il modello colloca correttamente il ritrovamento nell'ottobre del 2008, nei pressi del cimitero di Vagli di Sopra, e descrive la Fanciulla di Vagli come una sepoltura ligure-apuana contenente i resti di una cremazione, riferibili a un individuo di sesso femminile di età compresa tra i dodici e i quattordici anni.

La risposta fornisce un inquadramento storico e culturale del reperto, collocandolo nel contesto delle guerre tra Roma e i Liguri Apuani nel II secolo a.C. e interpretando la sepoltura come appartenente a una famiglia di alto rango sociale. La struttura del testo è chiara e ben organizzata, seguendo uno schema tipico della divulgazione archeologica di qualità.

## 7.2 Analisi dell'errore

A differenza degli altri modelli analizzati, Gemini non produce errori fattuali rilevanti rispetto ai dati verificabili. Il contesto cronologico (primi decenni del II secolo a.C.), la tipologia del reperto (sepoltura con urna cineraria), l'età stimata dell'individuo (dodici-quattordici anni) e l'associazione con la popolazione dei Liguri Apuani risultano sostanzialmente corretti.

## 7.3 Strategie discorsive

Dal punto di vista discorsivo, la risposta di Gemini adotta uno stile tipico della divulgazione storica di qualità, caratterizzato da una struttura chiara, un linguaggio accessibile e un tono informativo autorevole. L'organizzazione del contenuto e la progressione tematica favoriscono una comprensione efficace del reperto e del suo contesto.

La strategia narrativa principale consiste nell'inserimento del reperto in un quadro storico più ampio, in particolare quello delle guerre romano-liguri del II secolo a.C. Questa contestualizzazione è pertinente e contribuisce ad arricchire l'interpretazione del ritrovamento.

Le componenti interpretative — relative allo status sociale della giovane e al significato del corredo funebre — sono introdotte attraverso marcatori di probabilità e formulazioni ipotetiche ("suggerisce che", "probabilmente", "potrebbe essere stata" ). Tuttavia, tali segnali di cautela restano limitati e non incidono sulla struttura complessiva del racconto, che si presenta come lineare e concluso. Il modello privilegia una narrazione coerente e completa, riducendo lo spazio per la problematizzazione e per l'esplicitazione dei margini di incertezza propri dell'interpretazione archeologica.

## 7.4 Gestione delle fonti

In risposta alla richiesta di indicare le fonti utilizzate, il modello Gemini fornisce un elenco articolato di pubblicazioni scientifiche, enti istituzionali e musei, presentato con una struttura e un linguaggio tipici dell'apparato bibliografico accademico. Questa formulazione conferisce alla risposta un'elevata autorevolezza percepita.

La criticità principale non riguarda la plausibilità delle fonti citate né l'eventuale ricorso a ricerche esterne, bensì la mancanza di trasparenza nel rapporto tra fonti e affermazioni. Il modello non esplicita il nesso tra evidenze e interpretazioni, né distingue in modo sistematico tra dati attestati e inferenze.

# 8 Conclusioni

L'analisi comparativa delle risposte prodotte dai diversi Large Language Models mostra come gli errori osservati non siano uniformi, ma assumano forme differenti a seconda delle strategie adottate dai modelli. In alcuni casi si verifica una sostituzione del referente con elementi folklorici o simbolicamente noti; in altri, la costruzione di oggetti plausibili ma inesistenti attraverso l'assemblaggio di dati reali; in altri ancora, l'estensione interpretativa di informazioni corrette presentata come conoscenza consolidata.

Un elemento trasversale riguarda il ruolo delle strategie discorsive. La coerenza narrativa, il tono autorevole e la precisione apparente dei dettagli contribuiscono a rendere le risposte persuasive anche in presenza di errori rilevanti.L'errore non si presenta sotto forma di esitazione o incertezza, ma come una risposta formulata in modo sicuro e definitivo, senza traccia di *hedging*. I modelli tendono a offrire spiegazioni complete e autosufficienti, che non segnalano margini di dubbio né distinguono chiaramente tra fatti accertati e interpretazioni.

Un altro elemento riguarda il rapporto tra gli errori osservati e la capacità dei modelli di stimare la propria incertezza. Gli LLM sono in grado, almeno in condizioni controllate, di distinguere tra risposte più o meno affidabili e di assegnare una probabilità alla correttezza delle proprie risposte (Kadavath et al. 2022). Tuttavia, la natura stessa della generazione sequenziale di testo agisce come un filtro che appiattisce l'incertezza statistica in favore di una fluidità sintattica spesso ingannevole.

La gestione delle fonti conferma questa dinamica. La citazione di riferimenti reali e plausibili non garantisce la correttezza epistemica del contenuto e può, in alcuni casi, rafforzare la credibilità di risposte errate. Anche la trasparenza procedurale sul funzionamento del modello non si traduce necessariamente in una revisione critica dell'output.

Nel complesso, lo studio evidenzia come, in condizioni di scarsità informativa, gli LLM ricorrano a strategie di sostituzione e narrazione culturalmente plausibili. Ne deriva la necessità di un approccio critico che non si limiti alla verifica fattuale, ma

consideri le modalità discorsive attraverso cui la conoscenza viene costruita e resa affidabile.

## Riferimenti bibliografici


Breum, Simon Martin et al. (2024). «The Persuasive Power of Large Language Models». In: *Proceedings of the 18th International AAAI Conference on Web and Social Media (ICWSM 2024)*. Buffalo, NY, USA, pp. 152–163. DOI: 10.1609/icwsm.v18i1.31304.

Burrell, Jenna (2016). «How the Machine "Thinks": Understanding Opacity in Machine Learning Algorithms». In: *Big Data & Society* 3.1, pp. 1–12. DOI: 10.1177/2053951715622512.

Ji, Zhiwei et al. (2023). «Survey of Hallucination in Natural Language Generation». In: *ACM Computing Surveys* 55.12, pp. 1–38. DOI: 10.1145/3571730.

Kadavath, Saachi et al. (2022). «Language Models (Mostly) Know What They Know». In: *arXiv preprint arXiv:2207.05221*. URL: https://arxiv.org/abs/2207.05221.

Latour, Bruno (1987). *Science in Action: How to Follow Scientists and Engineers Through Society*. Cambridge, MA: Harvard University Press.

Li, Moxin et al. (2024). «Knowledge Boundary of Large Language Models: A Survey». In: *arXiv preprint* abs/2412.12472. arXiv: 2412.12472. URL: https://arxiv.org/abs/2412.12472.

LUBRANO, Filippo (ago. 2025). *Beyond Hallucinations: Emphatic Epanorthosis on LLMs*. Data paper, Zenodo. DOI: 10.5281/zenodo.16947334. URL: https://doi.org/10.5281/zenodo.16947334.

Magnus, Peder (2009). «On Trusting Wikipedia». In: *Episteme* 6.1, pp. 74–90.

Mallen, Alex et al. (2023). «When Not to Trust Language Models: Investigating Effectiveness of Parametric and Non-Parametric Memories». In: *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL)*. Association for Computational Linguistics, pp. 8856–8877. URL: https://arxiv.org/abs/2212.10511.

Ninno, Fabio De e Michele Lacriola (2025). «Mussolini and ChatGPT: Examining the risks of A.I. writing historical narratives on Fascism». In: *Journal of Modern Italian Studies*. Ahead of print, published online 18 Feb 2025. DOI: 10.1080/1354571X.2025.2457250. URL: https://www.tandfonline.com/doi/abs/10.1080/1354571X.2025.2457250.